



Détection automatique par IA pour caractériser le transport de matières dangereuses (TMD)

Dimitri Klockenbring

Master 2 CSMI

Stage encadré par Christophe Heinkelé et Guillaume Gublin

Introduction générale



Source: Google Maps

Circulation de véhicules transportant des matières dangereuses (**TMD**) au tunnel de Schirmeck



Introduction générale

Prévention des risques

- Signalisation ADR pour le transport des matières dangereuses



- Statistiques demandées au gestionnaire du tunnel (CeA)
 - Doit fournir des **comptages** des TMD
 - Deux campagnes de comptage manuelles par an
 - Statistique laborieuse et peu fiable

Comment fiabiliser les statistiques?

Introduction générale

Projet du Cerema en partenariat avec la CeA

- Objectif : application de **comptage automatique** des TMD
- Approche par **apprentissage supervisé profond**



Introduction générale

Projet du Cerema en partenariat avec la CeA

- Objectif : application de **comptage automatique** des TMD
- Approche par **apprentissage supervisé profond**



Introduction générale

Projet du Cerema en partenariat avec la CeA

- Objectif : application de **comptage automatique** des TMD
- Approche par **apprentissage supervisé profond**



Introduction générale

Projet du Cerema en partenariat avec la CeA

- Objectif : application de **comptage automatique** des TMD
- Approche par **apprentissage supervisé profond**



Introduction générale

Projet du Cerema en partenariat avec la CeA

- Objectif : application de **comptage automatique** des TMD
- Approche par **apprentissage supervisé profond**



Plan de l'exposé

Détection automatique par IA pour caractériser le transport de matières dangereuses (TMD)

- 1 Introduction générale
- 2 Contexte et objectifs du stage
- 3 Acquisition et traitement des données
- 4 Méthodologie pour la mise en œuvre des modèles
- 5 Classification d'images de véhicules
- 6 Détection de plaques TMD
- 7 Conclusion et perspectives

Contexte et objectifs du stage

Le Cerema

Centre d'Études et d'expertise sur
les Risques, l'Environnement, la Mobilité et l'Aménagement

- Établissement public créé en 2014
- Missions autour de l'**aménagement** et du **développement durable**
- Collaboration avec les collectivités locales



Contexte et objectifs du stage

L'équipe de recherche ENDSUM

Évaluation Non Destructive des StrUctures et des Matériaux

- Une vingtaine d'agents à Strasbourg, Angers, Rouen
- Méthodes de diagnostic non invasives
- Traitement d'**images** et d'autres signaux par reconnaissance des formes, reconstruction, **intelligence artificielle**



Contexte et objectifs du stage

Détection automatique par IA pour caractériser le transport de matières dangereuses (TMD)

Objectifs du stage

- Mise en œuvre et évaluation de méthodes d'apprentissage profond pour la **reconnaissance des TMD**
- Choix et adaptation d'architectures neuronales (**classification, détection**) au cas d'étude
- **Entraînement** des modèles sur des images annotées
- **Évaluation** des performances sur des données test
- Traitement et incorporation des nouvelles images au corpus de données

Contexte et objectifs du stage

Détection automatique par IA pour caractériser le transport de matières dangereuses (TMD)

Outils et organisation

- Outils
 - ▶ Scripts développés en langage Python (librairies Keras et Tensorflow)
 - ▶ Station de travail avec deux GPUs NVIDIA Quadro RTX 5000
- Organisation
 - ▶ Points d'avancement en équipe (projet/stage)
 - ▶ Séminaires avec les autres stagiaires

Acquisition et traitement des données

Chaîne de traitement des images

- ① Acquisition
- ② Détramage
- ③ Tri manuel en 5 classes
- ④ Annotation des plaques TMD



Acquisition et traitement des données

Chaîne de traitement des images

- ① Acquisition
- ② Détramage
- ③ Tri manuel en 5 classes
- ④ Annotation des plaques TMD



Acquisition et traitement des données

Chaîne de traitement des images

- ① Acquisition
- ② Détramage
- ③ Tri manuel en 5 classes
- ④ Annotation des plaques TMD



Acquisition et traitement des données

Chaîne de traitement des images

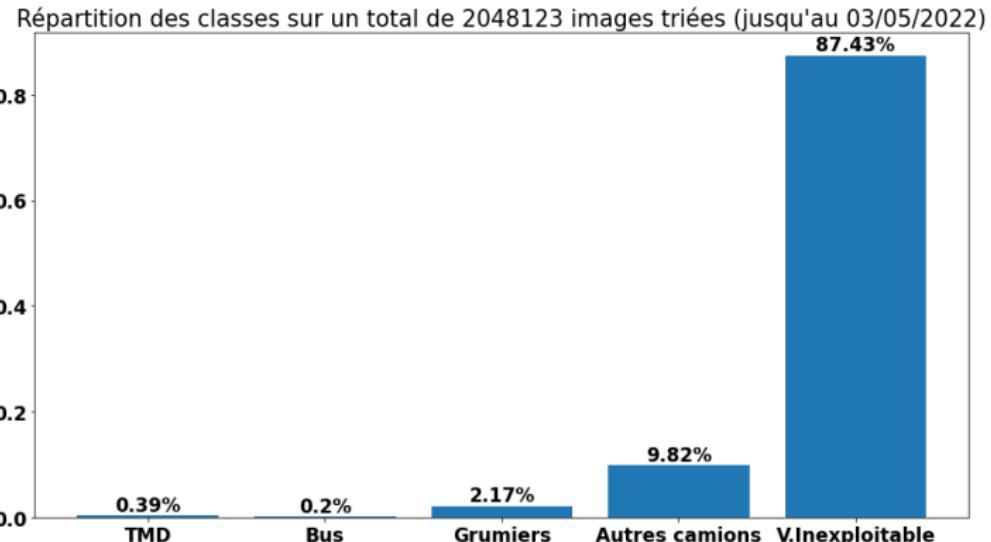


Interface d'annotation de LabelImg [1]

Acquisition et traitement des données

Corpus de données à l'issue du stage

- Environ **2 millions** d'images triées dont 8 000 images de TMD
- Environ **4 000** images de TMD annotées



Méthodologie

- ① Préparation des images (tri, annotation, prétraitements...)
- ② Choix et adaptation d'une architecture
- ③ Création de bases de données d'apprentissage
- ④ Entraînement du modèle
- ⑤ Création de bases de données test indépendantes
- ⑥ Évaluation des performances à **deux niveaux**
 - ▶ Théorique (sur une base test d'apprentissage)
 - ▶ Pratique (sur des images issues d'une journée test)

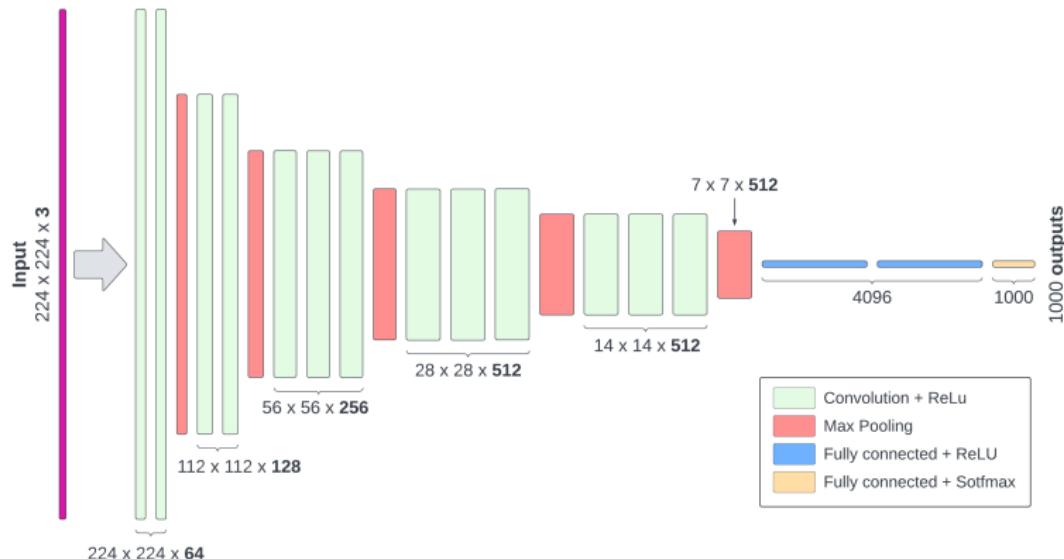
Classification d'images de véhicules

Classifier une image = lui associer une ou plusieurs classes

- Objectif : classification binaire **noPL/PL** pour accélérer le tri
- Données de départ : images triées en cinq classes
(Bus, Grumiers, TMD, Autres camions, Inexploitable)
- Préparation des données : regroupement en deux classes
 - ▶ "Inexploitable"
→ classe **noPL** (absence de poids lourd)
 - ▶ "Bus + Grumiers + TMD + Autres camions"
→ classe **PL** (présence de poids lourd)

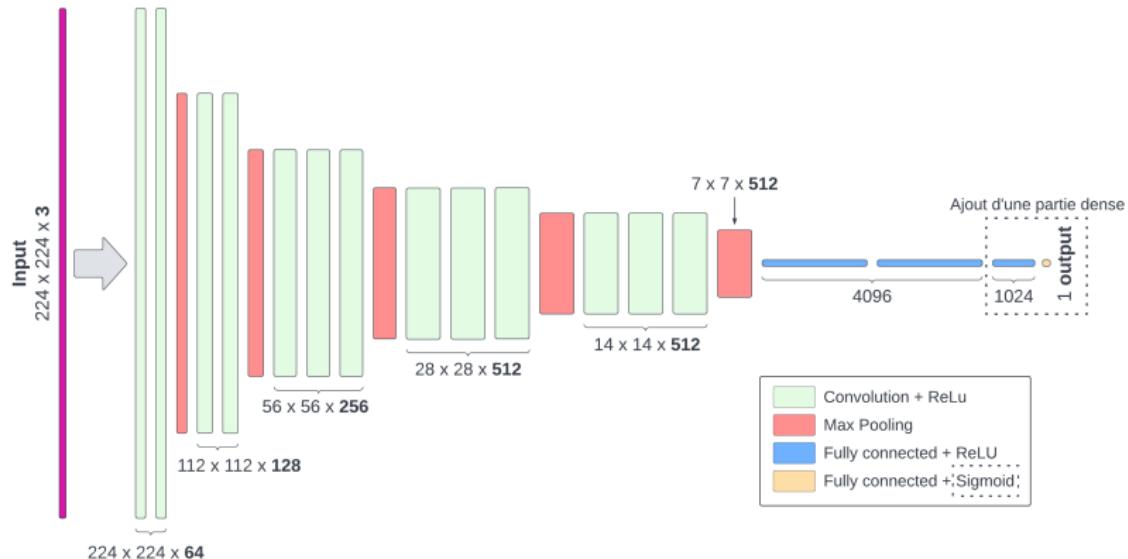
Classifieur VGG16 (2015 [5])

- Environ **140 millions** de paramètres
- Modification des dernières couches (1000 classes \rightarrow 1 classe)
- Modèle préentraîné + premières couches figées



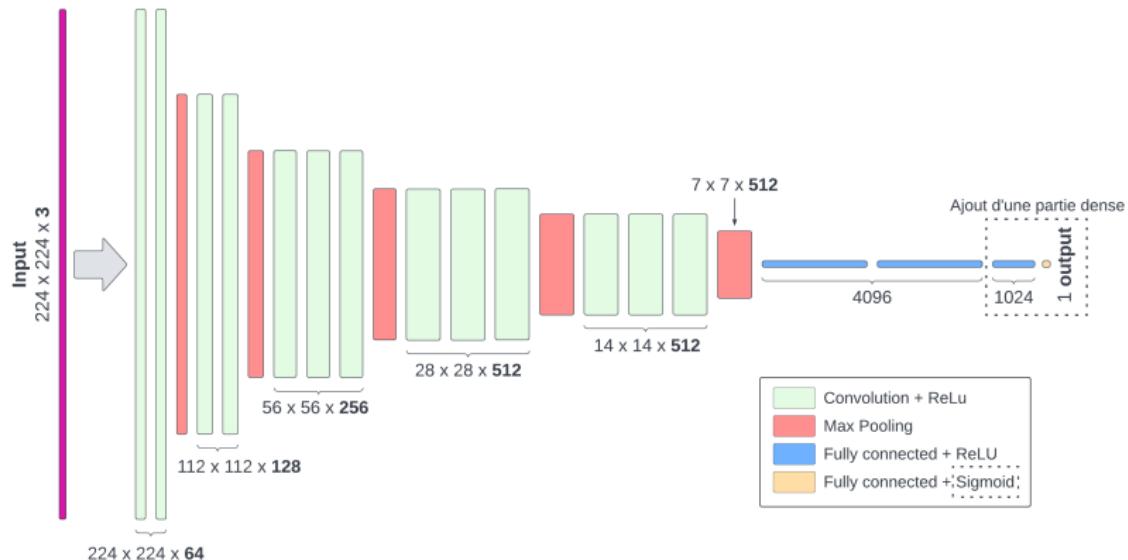
Classifieur VGG16 (2015 [5])

- Environ **140 millions** de paramètres
- Modification des dernières couches (**1000 classes → 1 classe**)
- Modèle préentraîné + premières couches figées



Classifieur VGG16 (2015 [5])

- Environ **140 millions** de paramètres
- Modification des dernières couches (1000 classes → 1 classe)
- **Modèle préentraîné + premières couches figées**



Évaluation du classifieur noPL/PL

Base de données d'apprentissage (55 000 images)

Classes binaires	PL				noPL
	Sous-classes	Bus	Grumiers	TMDs	
Nombre d'images	1724	10449	2738	17458	23178
Pourcentage	3.1%	18.8%	4.9%	31.4%	41.7%

Métriques d'évaluation

- **Rappel** : capacité du modèle à bien reconnaître les exemples de la classe souhaitée (bon quand il y a peu de faux négatifs)
- **Précision** : fiabilité des prédictions du modèle pour une classe donnée (bonne quand il y a peu de faux positifs)
- **Score F1** : moyenne harmonique de la précision et du rappel

Évaluation du classifieur noPL/PL

Évaluation théorique

Base de test théorique (6 000 images)

Classes binaires	PL				noPL
Sous-classes	Bus	Grumiers	TMDs	Autres camions	V.Inexploitable
Nombre d'images	149	1126	276	1854	2765
Pourcentage	2.4%	18.2%	4.5%	30.0%	44.8%

Performances noPL/PL

	noPL	PL
Rappel	94.9%	96.9%
Précision	96.1%	95.9%
Score F1	95.5%	96.4%

(a) Performances

		Prédiction	
		noPL	PL
Vérité	noPL	2624	141
	PL	106	3299

(b) Matrice de confusion

Évaluation du classifieur noPL/PL

Évaluation pratique

Base de test applicative (10 journées test)

Classes binaires	PL				noPL
Sous-classes	Bus	Grumiers	TMDs	Autres camions	V.Inexploitable
Nombre d'images	233	2539	431	12160	166156
Pourcentage	0.1%	1.4%	0.2%	6.7%	91.5%

Performances noPL/PL

	noPL	PL
Rappel	96.7%	96.3%
Précision	99.6%	72.8%
Score F1	98.1%	82.9%

(a) Performances

		Prédiction	
		noPL	PL
Vérité	noPL	160622	5534
	PL	570	14793

(b) Matrice de confusion

Évaluation du classifieur noPL/PL

Conclusion sur la classification

- Bonne performance du classifieur **noPL/PL**
 - ▶ Modèle utilisé pour faciliter le tri des images
- Performances médiocres en classification TMD/noTMD:
 - ▶ Fort déséquilibre des classes
 - ▶ Silhouette du véhicule non fiable !



Détection de plaques TMD

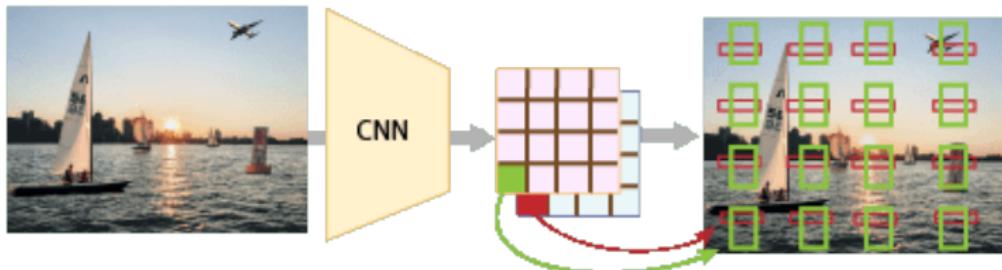
Détection = localisation + classification (boîtes englobantes)

- Objectif : détecter les plaques TMD à l'arrière des véhicules
- Préparation des données : annotation manuelle des plaques TMD
→ plaques losange, panneaux orange codifiés, panneaux orange vierges



Modèles de détection

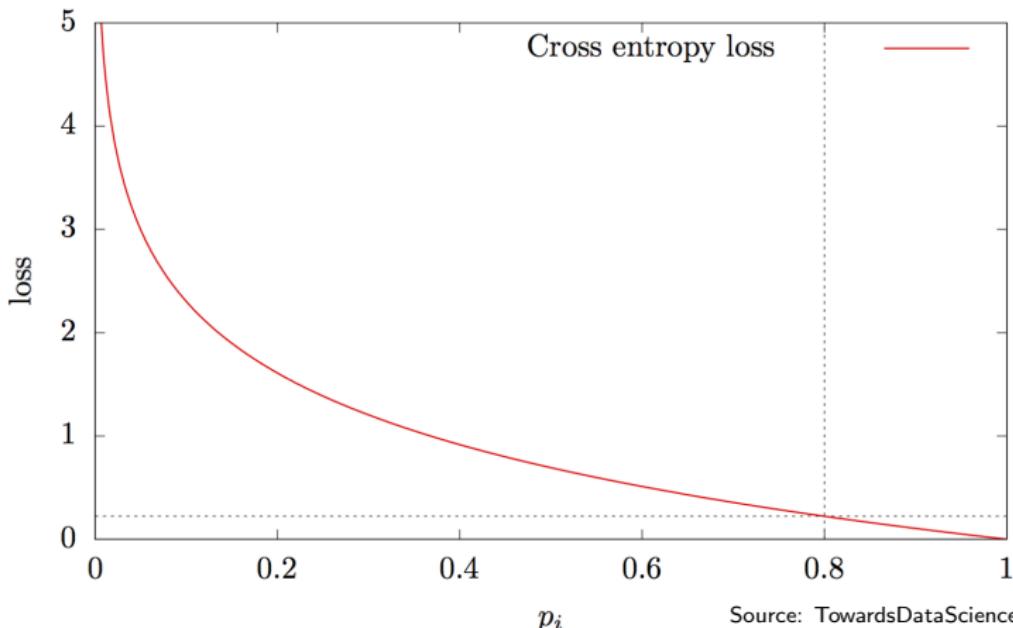
- Extraction de caractéristiques avec un réseau de neurones convolutif
- Ancres = boîtes englobantes prédéfinies
(position, proportions, échelle)
- Ajustement (**régression**) + Analyse du contenu (**classification**)
- Approche *one-shot* vs. *two-shot*



Source: mathworks.com

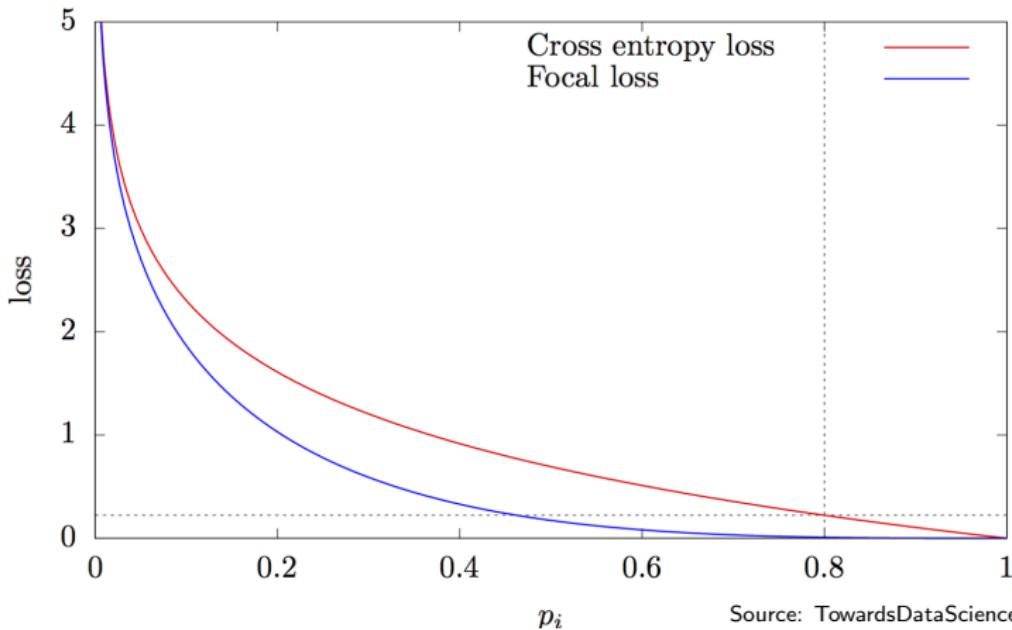
Détecteur RetinaNet (2018 [3])

- Détecteur *one-stage* → problème de **déséquilibre des classes**



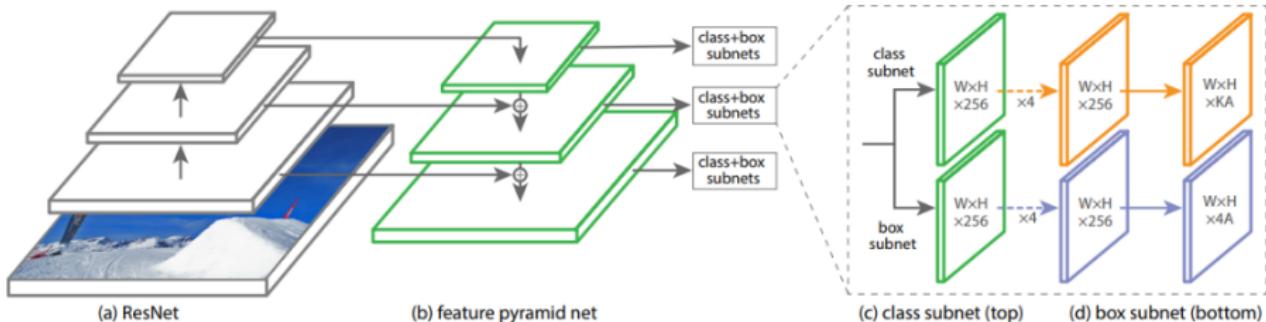
Détecteur RetinaNet (2018 [3])

- Détecteur *one-stage* → problème de **déséquilibre des classes**
- Fonction de coût : *Focal Loss*



Détecteur RetinaNet (2018 [3])

- Détecteur *one-stage* → problème de **déséquilibre des classes**
- Fonction de coût : *Focal Loss*
- Environ **35 millions** de paramètres
- CNN préentraîné pour l'extraction des caractéristiques (ResNet [2])
- Ancres : 5 échelles, 6 ratios



Source: [3]

Évaluation du détecteur de plaques TMD

Qualification des détections

- nombre de boîtes de la vérité terrain \neq nombre de boîtes prédites
- notion d'**IoU** pour qualifier les bonnes détections (choix d'un seuil)



$$\text{IOU} = \frac{\text{area of overlap}}{\text{area of union}} = \frac{\text{green overlap}}{\text{red + blue}}$$
A diagram illustrating the IoU formula. It shows two overlapping rectangles: a green one on top and a blue one below it. The area where they overlap is shaded in purple. The total area of the union of the two rectangles is shown as the sum of their individual areas minus the overlapping area.

Source: [4]

Évaluation du détecteur de plaques TMD

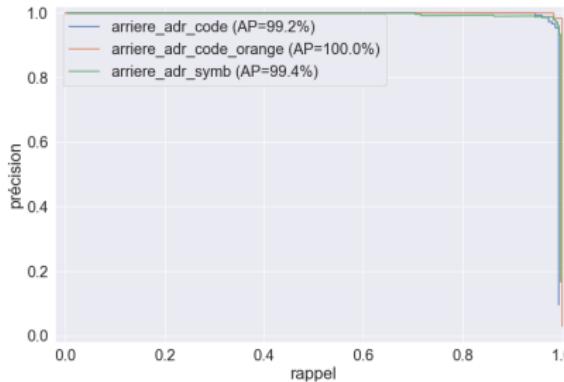
Quatre bases de données d'apprentissage

		TMD	noTMD "courant"	noTMD "difficile"
DB1	Train	1385	-	-
	Validation	297	-	-
	Test	297	-	-
DB2	Train	1385	1380	-
	Validation	297	296	-
	Test	297	300	-
DB3	Train	1385	-	1380
	Validation	297	-	296
	Test	297	-	300
DB4	Train	1385	1380	1380
	Validation	297	296	296
	Test	297	300	300

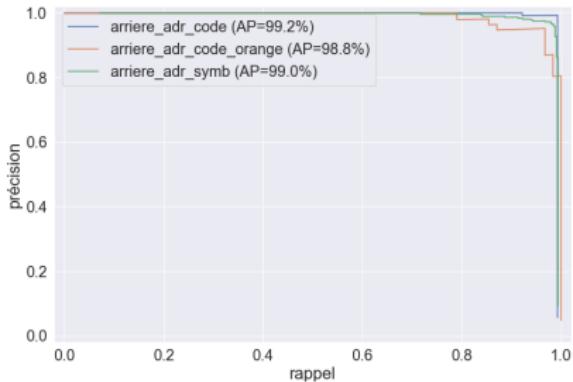
Évaluation du détecteur de plaques TMD

Évaluation théorique

- Courbes précision/rappel (un point par seuil de décision)
- Précision moyenne (AP) = intégrale de la courbe précision/rappel
- mAP (*mean Average Precision*) = moyenne des AP



(a) DB1 (mAP=99.5%)



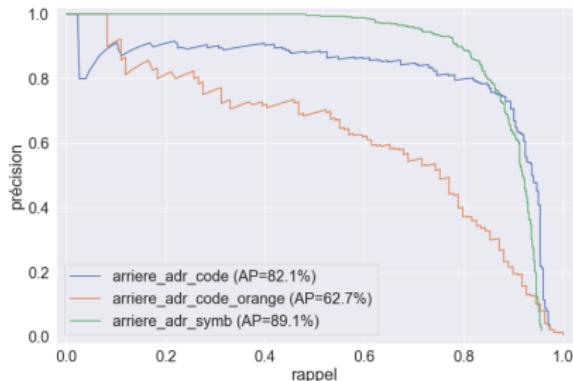
(b) DB4 (mAP=99.0%)

Évaluation du détecteur de plaques TMD

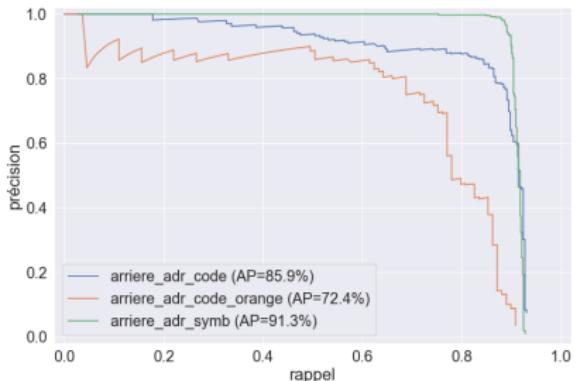
Évaluation pratique

Base de test applicative

- Images de la journée du 17 mai 2022
- Environ 500 images TMD et 50 000 images noTMD



(a) DB1 (mAP=78.8%)



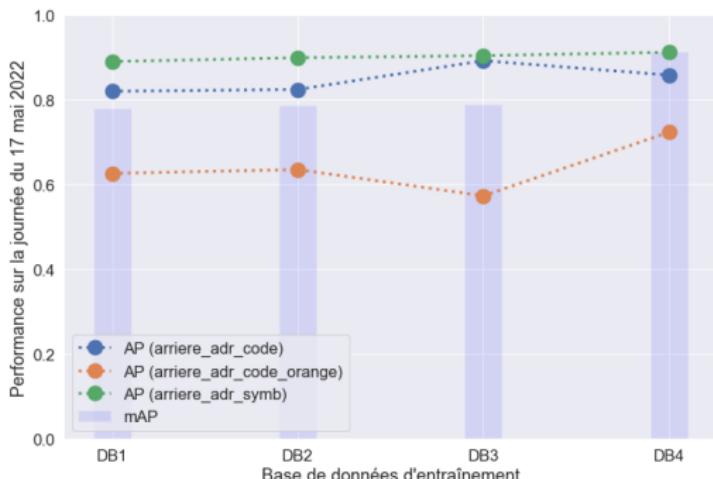
(b) DB4 (mAP=83.2%)

Évaluation du détecteur de plaques TMD

Évaluation pratique

Base de test applicative

- Images de la journée du 17 mai 2022
- Environ 500 images TMD et 50 000 images noTMD



Évaluation du détecteur de plaques TMD

Évaluation pratique pour le comptage des TMD

Base de test applicative

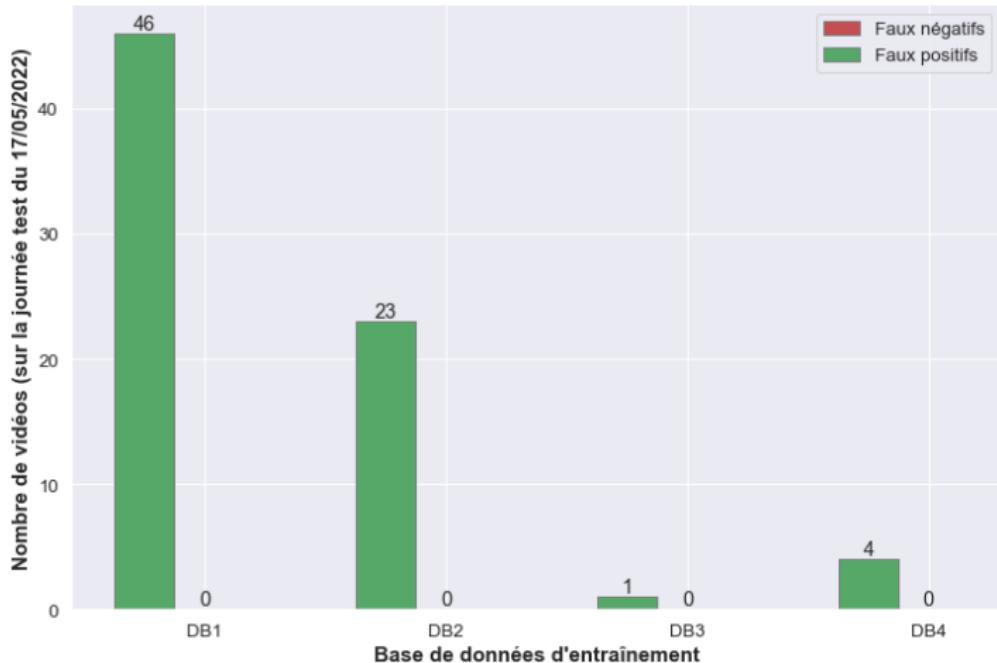
- Images de la journée du 17 mai 2022
- 19 vidéos TMD et 640 vidéos noTMD

Utilisation du détecteur pour classifier les vidéos

- Objectif : décider si une vidéo contient ou non un TMD
- Hypothèse de travail : maximum un TMD dans une séquence vidéo
- Critère : au moins une détection avec une confiance $> 90\%$

Évaluation du détecteur de plaques TMD

Évaluation pratique pour le comptage des TMD



Évaluation du détecteur de plaques TMD

Conclusion sur la détection

- Bonnes performances "brutes" (théoriques et pratiques)
- Comptage → performances prometteuses (100% des TMD trouvés)
- Importance des exemples négatifs pour réduire les fausses détections



Conclusion et perspectives

Travail réalisé

- Mise en œuvre d'algorithmes d'apprentissage (classification, détection)
- Entraînement et évaluation (théorique et pratique)
- Performances prometteuses pour la reconnaissance des TMD

Perspectives : collaboration avec la CeA pour le comptage des TMD

- Étape de Go/No-go en novembre
- Mener plus loin les travaux
 - ▶ Perfectionnement des modèles (architectures, apprentissage)
 - ▶ Post-traitements pour fiabiliser les inférences
(position, contenu, taille, mouvement, redondance des boîtes englobantes...)
 - ▶ Comptage des véhicules
 - ▶ Analyse du contenu des plaques (symboles, codes)

Bibliographie I

-  darrenl.
LabellImg, May 2022.
original-date: 2015-09-17T01:33:59Z.
-  Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun.
Deep Residual Learning for Image Recognition.
In *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, Las Vegas, NV, USA, June 2016. IEEE.
-  Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár.
Focal Loss for Dense Object Detection.
arXiv:1708.02002 [cs], February 2018.
arXiv: 1708.02002 version: 2.

Bibliographie II

-  Rafael Padilla, Wesley L. Passos, Thadeu L. B. Dias, Sergio L. Netto, and Eduardo A. B. da Silva.
A Comparative Analysis of Object Detection Metrics with a Companion Open-Source Toolkit.
Electronics, 10(3):279, January 2021.
-  Andrew Zisserman and Karen Simonyan.
Very Deep Convolutional Networks for Large-Scale Image Recognition.
arXiv:1409.1556 [cs], April 2015.
arXiv: 1409.1556.